

AI Agent 是一种能够根据目标自主决定下一步操作，并通过调用工具完成任务的人工智能系统。普通聊天机器人主要负责根据用户输入生成文字回答，而 AI Agent 除了生成内容之外，还可以根据任务需要选择和调用外部工具。

例如，一个 AI Agent 可以调用搜索工具查找信息，可以调用数据库查询数据，也可以调用 API 获取天气、发送邮件或者操作其他软件。大语言模型在 Agent 系统中通常负责理解用户目标、进行推理，并决定什么时候需要使用某个工具。

一个简单的 Agent 工作流程可以分为几个步骤。首先接收用户提出的任务，然后分析完成任务需要哪些信息。如果当前信息不足，Agent 可以调用工具获取新的信息。获得工具返回的结果以后，Agent 会继续进行判断，必要时再次调用工具，直到能够完成任务。

因此，AI Agent 和普通大语言模型应用的重要区别之一，就是 Agent 不只是回答问题，而是可以通过工具与外部环境进行交互并完成实际任务。Tool Calling 是构建 Agent 时非常重要的基础能力。

Embedding 是一种将文本转换成数值向量的技术。经过 Embedding 模型处理以后，一段文字可以被表示成由许多数字组成的向量。这个向量可以表示文本在语义空间中的特征，因此语义相近的文本通常会得到距离比较接近的向量。

在语义检索中，Embedding 可以解决传统关键词匹配的一些问题。例如，“人工智能代理”和“AI Agent”虽然使用了不同的文字，但是它们的语义非常接近。Embedding 模型可以把这种语义关系编码到向量中，因此系统不需要要求两个文本包含完全相同的关键词。

在 RAG 系统中，通常会先对所有文档 Chunk 进行 Embedding，并把得到的向量保存到向量数据库。当用户提出问题时，系统也会对问题进行 Embedding，然后计算问题向量和文档向量之间的相似度。

常见的相似度计算方法包括余弦相似度。相似度越高，通常表示问题和这个 Chunk 在语义上越接近。系统可以按照相似度排序并选择 Top-K 个最相关的 Chunk，再把这些内容交给大语言模型生成最终回答。

RAG 的全称是 Retrieval-Augmented Generation，中文通常叫做检索增强生成。它的主要作用是让大语言模型在回答问题之前，先从外部知识库中检索与用户问题相关的内容，再根据检索结果生成回答。

一个典型的 RAG 系统通常包含文档处理、文本切分、Embedding、向量数据库、检索和大语言模型生成几个步骤。原始文档首先会被切分成多个 Chunk，每个 Chunk 再通过 Embedding 模型转换成向量，并保存到向量数据库中。

当用户提出问题时，系统也会把问题转换成向量，然后与向量数据库中的 Chunk 进行相似度比较，找到最相关的几个 Chunk。最终，这些检索到的内容会作为 Context 提供给大语言模型，大语言模型根据 Context 回答用户的问题。

RAG 的一个重要优点是可以让大语言模型使用自己的训练数据之外的知识，例如企业内部文档、个人笔记或者最新资料。同时，由于回答可以基于真实检索到的文档内容，RAG 也能够一定程度上降低大语言模型产生幻觉的概率。